

面向强约束三维无人机路径规划的约束可行性场驱动进化搜索

作者、单位与通讯作者信息待补

2026 年 8 月 8 日

摘要

强约束低空无人机路径规划需同时满足障碍物、禁飞区、高度边界和路径平滑性等条件。针对基础进化搜索在狭窄可行走廊中易产生不可行个体和低质量绕行的问题,本文提出约束可行性场驱动的自适应进化搜索方法(CVF-AE)。该方法将障碍物、禁飞区、风险、高度、边界和转弯信息映射为控制点层面的有界分段压力,在候选生成阶段提供局部约束感知方向。CVF-AE结合约束感知初始化、保守状态调度和稀疏触发,仅为少量关键个体生成CVF增强候选,并以Deb优先且含惩罚综合适应度不增的局部门控决定是否保留。三类合成低空三维场景结果表明,在本文离散采样判定下,CVF-AE在所选代表性基线中保持1.00可行率并取得最佳平均排名;消融结果显示CVF增强候选分支、约束感知初始化、三状态调度和稀疏可行性保持均对完整方法产生贡献。该分支触发率低于1%;相对同配置w/o-CVF版本,三场景平均额外评价次数约为0.44%。CVF-AE因而可作为静态合成强约束低空路径规划的候选生成框架。

关键词: 无人机路径规划; 约束优化; 进化算法; 约束可行性场; 启发式优化

1 引言

低空无人机在巡检、监测、配送和应急响应等任务中具有部署灵活和快速到达的优势。在建筑密集、禁飞区交错且风险分布不均的低空空间中,路径规划需要同时权衡障碍物避让、禁飞区规避、高度边界、转弯平滑性、风险暴露和能耗,而非仅寻找一条短路径。已有综述将UAV路径规划概括为图搜索、采样、数学规划、智能优化、学习和混合等多类路线,并指出复杂环境中的三维可行性保持与多约束折中仍是核心问题[1, 2]。

围绕复杂约束下的搜索效率与路径质量,同行已

从初始化、候选生成、更新和局部引导等环节提出改进。Darlan 等将 A* 引导的交叉、变异和自适应多项式变异嵌入进化算法[3]; Niu 等在连续蚁群优化中结合随机游走和自适应路径点修复[4]; Chen 等面向多 UAV 威胁环境,将偏置采样、候选评价和路径重构整合到 RRT* 框架[5]; Wang 等在多目标水母搜索中利用 RRT 初始化和类别最优个体引导改善初始路径与搜索压力[6]; Meng 等则通过自适应算子选择和知识融合增强进化多任务路径搜索[7]。在局部方向引导方面, Khatib 提出了经典人工势场思想[8], Liu 等进一步以旋转势场和参数学习服务多 UAV 协同规划[9]。这些研究说明领域知识可以有效参与搜索,但本文所面对的痛点不同:对于单条强约束 B 样条路径,惩罚项和 Deb 规则只能在候选评价后识别不可行性;而若将局部方向强制施加给全种群,又可能干扰基础进化搜索。因此,需要一种能够在评价前提供局部约束方向、按群体状态稀疏介入,并以保守规则限制替换范围的候选生成机制。

针对上述不足,本文提出约束可行性场驱动的自适应进化搜索方法(Constraint Viability Field guided Adaptive Evolution, CVF-AE)。本文不以 CVF 替代基础 AE 或构造新的目标函数,而是将其设计为候选生成中的局部修正机制:约束感知初始化和参考弱引导首先帮助种群进入潜在可行走廊;形成、保持和恢复三种状态根据群体可行性与搜索进展决定何时介入;对少量近可行候选,CVF 将障碍物、禁飞区、风险、高度、边界和转弯信息编码为有界控制点增量;候选仅在 Deb 顺序改善且含惩罚综合适应度不增加时才被保留。由此,初始化、状态调度、场构建和保守接收共同构成一个在不接管全局搜索前提下前移约束信息的闭环。基于这一思路,本文的贡献如下:

- 提出面向 B 样条控制点编码的 CVF 表示,将障碍物、禁飞区、高度与边界等局部约束信息,以及

风险和转弯等质量信息,映射为控制点层面的有界方向增量,使局部信息在候选评价前参与搜索,而不只通过目标项和惩罚项事后体现。

- 设计以“进入-介入-移动”为主线的稀疏候选增强框架:约束感知初始化提供弱先验,三状态调度和近可行触发决定介入时机与对象,基础 AE 方向与 CVF 方向在受限步长内融合,从而保留全局进化搜索的主体地位。
- 给出“接受-替换”的保守边界:CVF 候选经过边界投影后,须同时满足局部 Deb 优先和含惩罚综合适应度不增条件才可替代基础候选;稀疏可行性保持仅作用于少量候选,以避免将局部修正扩展为全种群强制修复。

本文其余部分组织如下:第 2 节给出路径编码、目标函数、约束违反量和可行性准则;第 3 节介绍 CVF-AE 的候选生成、约束状态识别、CVF 构建和稀疏触发机制;第 4 节依次说明整体实验设置、主对比、消融、显著性和开销分析,并在相应小节内讨论结果含义与方法边界;最后给出结论。

2 问题建模

本文研究强约束三维低空无人机路径规划问题。给定三维飞行空间、起点、终点、障碍物、禁飞区和高度约束,目标是在安全可行前提下生成平滑路径。与仅最小化长度的规划不同,低空飞行还需兼顾能耗、风险暴露和转弯平滑性,并同时满足高度与空间边界约束。因此,本文将路径规划写成带约束的连续优化问题,并采用可行性优先准则比较候选解。

2.1 三维路径表示

设无人机起点和终点分别为 $\mathbf{s} = [x_s, y_s, z_s]^T$ 和 $\mathbf{g} = [x_g, y_g, z_g]^T$ 。优化变量为 K 个内部控制点:

$$\mathbf{X} = [\mathbf{q}_1^T, \mathbf{q}_2^T, \dots, \mathbf{q}_K^T]^T \in \mathbb{R}^{3K} \quad \mathbf{q}_k = [x_k, y_k, z_k]^T \quad (1)$$

完整控制点序列为

$$\mathcal{Q} = \{\mathbf{s}, \mathbf{q}_1, \dots, \mathbf{q}_K, \mathbf{g}\} \quad (2)$$

本文使用 open-uniform 三次 B 样条由控制点序列构造连续路径 $\mathbf{p}(u)$, $u \in [0, 1]$ 。实际评价中取 M 个均匀

采样点:

$$\mathcal{P}(\mathbf{X}) = \{\mathbf{p}_m\}_{m=1}^M \quad (3)$$

$$\mathbf{p}_m = \mathbf{p} \left(\frac{m-1}{M-1} \right) = [x_m, y_m, z_m]^T$$

因此 $\mathbf{p}_1 = \mathbf{s}$ 且 $\mathbf{p}_M = \mathbf{g}$ 。路径长度、风险、碰撞、禁飞区、高度和转弯约束均基于采样点序列计算,从而在较低控制点维度下统一处理多种空间约束。

2.2 优化目标

对任一路径 $\mathcal{P}(\mathbf{X})$, 本文采用综合路径质量代理目标

$$J(\mathbf{X}) = w_L L + w_E E + w_R R + w_S S + P_c \quad (4)$$

其中 L, E, R, S 分别表示长度、能耗、风险和平滑性, w_L, w_E, w_R, w_S 为对应权重。惩罚项 P_c 写为

$$P_c = \lambda_{\text{obs}} C_{\text{obs}} + \lambda_{\text{nfz}} C_{\text{nfz}} + \lambda_{\text{curv}} C_{\text{curv}} + \lambda_{\text{alt}} C_{\text{alt}} \quad (5)$$

式 (4) 中各目标项基于采样序列定义。令相邻采样点之间的段向量和段长分别为

$$\Delta \mathbf{p}_m = \mathbf{p}_{m+1} - \mathbf{p}_m, \quad \Delta l_m = \|\Delta \mathbf{p}_m\|_2 + \epsilon_l \quad (6)$$

其中 $m = 1, \dots, M-1$, ϵ_l 为防止零长度除法的极小常数。路径长度项定义为

$$L = \sum_{m=1}^{M-1} \Delta l_m \quad (7)$$

设 $\mathbf{w}_m$ 为第 m 段起点处的风场向量, $\hat{\mathbf{d}}_m = \Delta \mathbf{p}_m / \Delta l_m$ 为带除零保护的段方向, $\hat{\mathbf{w}}_m = \mathbf{w}_m / (\|\mathbf{w}_m\|_2 + \epsilon_l)$ 为带除零保护的风向方向。风阻相关项写为

$$\Phi_m = \|\mathbf{w}_m\|_2 \left(1 - \hat{\mathbf{d}}_m^T \hat{\mathbf{w}}_m \right) \quad (8)$$

能耗项由水平/空间飞行距离、垂向变化和逆风暴露共同构成:

$$E = \sum_{m=1}^{M-1} (a_1 \Delta l_m + a_2 |\Delta z_m| + a_3 \Phi_m) \quad (9)$$

其中 $\Delta z_m = z_{m+1} - z_m$, a_1, a_2, a_3 为能耗系数。若 $r_{\text{obj}}(\mathbf{p}_m)$ 为评价器使用的采样点风险密度, 则风险项定义为

$$R = \sum_{m=1}^{M-1} r_{\text{obj}}(\mathbf{p}_m) \Delta l_m \quad (10)$$

平滑性项定义为

$$S = \sum_{m=2}^{M-1} \|\mathbf{p}_{m+1} - 2\mathbf{p}_m + \mathbf{p}_{m-1}\|_2^2 \quad (11)$$

式 (9) 所定义的项为固定采样设置下的路径质量代理, 不解释为严格飞行动力学或真实能耗模型; 硬约束违反由下文单独判断。

2.3 约束条件

空间边界约束 设 $\mathbf{l}_0, \mathbf{u}_0 \in \mathbb{R}^3$ 为单个控制点的下界和上界, 并令 $\mathbf{l} = [\mathbf{l}_0^\top, \dots, \mathbf{l}_0^\top]^\top$ 、 $\mathbf{u} = [\mathbf{u}_0^\top, \dots, \mathbf{u}_0^\top]^\top$ 。决策空间为 $\Omega = \{\mathbf{X} \in \mathbb{R}^{3K} : \mathbf{l} \leq \mathbf{X} \leq \mathbf{u}\}$; 每个内部控制点和采样点均应位于对应的三维规划空间范围内, 即 $\mathbf{l}_0 \leq \mathbf{q}_k \leq \mathbf{u}_0$, $k = 1, \dots, K$ 。候选控制点越界时先通过 $\Pi_\Omega(\cdot)$ 投影回规划盒内。由于本文采用的 open-uniform B 样条基函数非负且和为 1, 路径点可写成控制点的凸组合; 若起点、终点和内部控制点均位于同一规划盒内, 则采样路径不会越出该盒。参考路径中的边界偏好仅提供软引导, 不构成目标函数项或额外硬边界判定。

障碍物约束 设障碍物集合为 $\mathcal{O}$ 。采样点不得进入障碍物, 即 $\mathbf{p}_m \notin \mathcal{O}$, $m = 1, \dots, M$ 。障碍物违反量按进入障碍物的采样点数量累计:

$$C_{\text{obs}} = \sum_{m=1}^M \mathbb{I}(\mathbf{p}_m \in \mathcal{O}) \quad (12)$$

其中 $\mathbb{I}(\cdot)$ 为指示函数。CVF 可在候选生成中使用近障碍缓冲压力, 但不改变式 (12) 的可行性判定。

禁飞区约束 设禁飞区集合为 $\mathcal{Z}$, 其中 $\mathcal{Z}$ 表示已合并安全缓冲后的禁飞区集合。路径采样点不得进入禁飞柱体或其安全缓冲范围, 即 $\mathbf{p}_m \notin \mathcal{Z}$, $m = 1, \dots, M$ 。禁飞区违反量同样按采样点进入禁飞区的次数统计:

$$C_{\text{nfz}} = \sum_{m=1}^M \mathbb{I}(\mathbf{p}_m \in \mathcal{Z}) \quad (13)$$

高度约束 无人机飞行高度需满足场景给定的下界和上界, 即 $z_{\min} \leq z_m \leq z_{\max}$, $m = 1, \dots, M$ 。若路径低于 $z_{\min}$ 或高于 $z_{\max}$, 对应超限距离累计为

$$C_{\text{alt}} = \sum_{m=1}^M [\max(0, z_{\min} - z_m) + \max(0, z_m - z_{\max})] \quad (14)$$

不同场景可采用不同高度上界和参考高度 z_{ref} , 以反映低空走廊收紧要求; z_{ref} 仅用于初始化和 CVF 的软引导, 不参与适应度函数。

转弯约束 令 $\mathbf{v}_m = \mathbf{p}_{m+1} - \mathbf{p}_m$ 。连续路径段形成的转弯角定义为

$$\theta_m = \arccos \left[\text{clip} \left(\frac{\mathbf{v}_{m-1}^\top \mathbf{v}_m}{\|\mathbf{v}_{m-1}\|_2 \|\mathbf{v}_m\|_2 + \epsilon_l}, -1, 1 \right) \right] \quad (15)$$

$$m = 2, \dots, M-1$$

其中 $\text{clip}(x, -1, 1)$ 表示将标量 x 截断到 $[-1, 1]$, 用于避免数值舍入导致反余弦输入越界。路径转弯角不应超过允许上限 $\theta_{\max}$, 即 $\theta_m \leq \theta_{\max}$, $m = 2, \dots, M-1$; 超出部分累计为

$$C_{\text{curv}} = \sum_{m=2}^{M-1} \max(0, \theta_m - \theta_{\max}), \quad (16)$$

从而将急转弯或局部折线化路径识别为不可行候选。

2.4 可行性准则

为避免不同量纲约束被误解为同一物理量, 本文首先将约束违反写成非负分量向量

$$\mathbf{c}(\mathbf{X}) = [C_{\text{obs}}, C_{\text{nfz}}, C_{\text{curv}}, C_{\text{alt}}]^\top \quad (17)$$

本文以四个非负分量之和定义总违反分数

$$V(\mathbf{X}) = C_{\text{obs}} + C_{\text{nfz}} + C_{\text{curv}} + C_{\text{alt}} \quad (18)$$

采用总违反分数阈值判定可行性, 即当且仅当 $V(\mathbf{X}) \leq \epsilon_v$ 时路径可行, 其中 $\epsilon_v = 10^{-10}$ 仅用于抑制浮点误差。各分量非负, 因而该判定仅表示固定采样点和离散转弯角满足数值容差, 而非采样点间连续轨迹的碰撞认证。 V 是依赖地图单位、采样数和弧度制的经验聚合分数, 仅用于不可行候选的排序和阈值判断。

候选解比较采用 Deb 可行性优先规则 [10]。对两个候选解 $\mathbf{X}_a$ 和 $\mathbf{X}_b$, 若仅一个解可行, 则可行解优先; 若二者均可行, 则含惩罚综合适应度 J 更小者优先; 若二者均不可行, 则 V 更小者优先; 若 V 相同, 再以 J 作为次级判据。该规则使不可行候选的排序倾向于降低总违反分数, 并在可行候选之间比较综合适应度。第 3 节将进一步说明 CVF-AE 如何利用这一可行性信息构造约束可行性方向。

3 CVF-AE 方法

CVF-AE 不以约束可行性场 (Constraint Viability Field, CVF) 替代基础自适应进化搜索, 而将其置于候选生成阶段: 障碍物、禁飞区、高度、转弯、边界和风险等局部约束与质量信息先构造为有界方向增量, 再仅作用于少量关键候选, 使这些信息在评价前提供局部移动建议, 同时保留基础搜索的全局探索职责。

3.1 基础 AE 与 CVF-AE 流程

算法 1 与算法 2 分别概括基础 AE 和 CVF-AE 的流程。两者共享第 2 节中的路径编码、目标函数、违反分数、边界投影和 Deb 规则。基础 AE 使用固定的平衡进化算子; CVF-AE 仅在稀疏触发时生成额外的约束引导候选, 并采用更严格的局部门控。

基础 AE 的候选由固定平衡进化方向、凸组合和边界投影构成:

$$\mathbf{X}_{\text{AE}} = \Pi_{\Omega}((1 - \eta_t - \mu_t)(\mathbf{X}_i + \mathbf{D}_{\text{AE}}) + \eta_t \mathbf{X}_i + \mu_t \mathbf{X}_{\text{elite}}) \quad (19)$$

其中 $\Pi_{\Omega}(\cdot)$ 为边界投影, $\mathbf{X}_{\text{elite}}$ 为精英池采样个体。令 $\tau = t/T$, $\mathbf{d}_{\text{best}} = \mathbf{X}^* - \mathbf{X}_i$, $\mathbf{d}_{\text{elite}} = \bar{\mathbf{X}}_{\text{elite}} - \mathbf{X}_i$, $\mathbf{d}_{\text{sample}} = \mathbf{X}_{\text{elite}} - \mathbf{X}_i$ 。从除当前个体 i 外的其余 $N - 1$ 个种群成员中, 等概率且不重复地随机选取四个不同的索引, 记为 a, b, c, d , 并定义 $\mathbf{d}_{ab} = \mathbf{X}_a - \mathbf{X}_b$, $\mathbf{d}_{cd} = \mathbf{X}_c - \mathbf{X}_d$; 另有 $\boldsymbol{\xi} \sim \mathcal{U}([-1, 1]^{3K})$ 。其方向为

$$\begin{aligned} \mathbf{D}_{\text{AE}} = & a_e \mathbf{r}_e \odot \mathbf{d}_{\text{elite}} + a_b \mathbf{r}_b \odot \mathbf{d}_{\text{best}} \\ & + a_d (\omega_d \mathbf{d}_{ab} + (1 - \omega_d) \mathbf{d}_{cd}) + a_s \mathbf{r}_s \odot \mathbf{d}_{\text{sample}} \\ & + a_u \rho_t \boldsymbol{\xi} \odot (\mathbf{u} - \mathbf{l}) \end{aligned} \quad (20)$$

Algorithm 1 基础 AE 路径搜索流程

Require: 地图 $\mathcal{M}$, 起点 s , 终点 g , 种群规模 N , 最大迭代次数 T

Ensure: 按 Deb 规则得到的当前最优路径 $\mathcal{P}^*$

```

1: 初始化种群  $\{\mathbf{X}_i\}_{i=1}^N$ , 并将控制点限制在边界内
2: 评价所有个体的  $J(\mathbf{X}_i)$  与  $V(\mathbf{X}_i)$ 
3: 按 Deb 可行性优先规则记录当前最优解  $\mathbf{X}^*$ 
4: for  $t = 1$  to  $T$  do
5:   for  $i = 1$  to  $N$  do
6:     构造固定基础进化方向  $\mathbf{D}_{\text{AE}}$ 
7:     按式 (19) 生成基础候选  $\mathbf{X}_{\text{AE}}$ 
8:     评价  $\mathbf{X}_{\text{AE}}$  的目标值和违反量
9:     if  $\mathbf{X}_{\text{AE}} \prec_{\text{Deb}} \mathbf{X}_i$  then
10:       $\mathbf{X}_i \leftarrow \mathbf{X}_{\text{AE}}$ 
11:   end if
12:   更新当前最优解  $\mathbf{X}^*$ 
13: end for
14: end for
15: return 由  $\mathbf{X}^*$  解码得到的路径  $\mathcal{P}^*$ 
```

Algorithm 2 CVF-AE 路径搜索流程

Require: 地图 $\mathcal{M}$, 起点 s , 终点 g , 种群规模 N , 最大迭代次数 T

Ensure: 按 Deb 规则得到的当前最优路径 $\mathcal{P}^*$

```

1: 生成参考控制序列, 并进行约束感知初始化
2: 评价所有个体的  $J(\mathbf{X}_i)$  与  $V(\mathbf{X}_i)$ 
3: 按 Deb 可行性优先规则记录当前最优解  $\mathbf{X}^*$ 
4: for  $t = 1$  to  $T$  do
5:   计算请求状态  $q_t$ , 并通过保守调度得到生效状态  $s_t$ 
6:   for  $i = 1$  to  $N$  do
7:     按生效状态构造内部基础候选  $\mathbf{X}_{\text{AE}}^{(s_t)}$ 
8:     评价  $\mathbf{X}_{\text{AE}}^{(s_t)}$  的目标值和违反量
9:     if 个体  $i$  满足 CVF 稀疏触发条件 then
10:      构造  $\mathbf{D}_{\text{CVF}}$  与  $\mathbf{D}_Q$ 
11:      按式 (51) 生成  $\mathbf{X}_{\text{CVF}}$ 
12:      评价  $\mathbf{X}_{\text{CVF}}$  的目标值和违反量
13:      if  $\mathbf{X}_{\text{CVF}} \prec_{\text{Deb}} \mathbf{X}_{\text{AE}}^{(s_t)}$  且  $J(\mathbf{X}_{\text{CVF}}) \leq J(\mathbf{X}_{\text{AE}}^{(s_t)})$  then
14:         $\mathbf{Y} \leftarrow \mathbf{X}_{\text{CVF}}$ 
15:      else
16:         $\mathbf{Y} \leftarrow \mathbf{X}_{\text{AE}}^{(s_t)}$ 
17:      end if
18:    else
19:       $\mathbf{Y} \leftarrow \mathbf{X}_{\text{AE}}^{(s_t)}$ 
20:    end if
21:    if  $\mathbf{Y}$  被选入稀疏可行性保持集合 then
22:      生成并评价局部修复候选  $\mathbf{X}_{\text{rep}}$ 
23:      if  $\mathbf{X}_{\text{rep}} \prec_{\text{Deb}} \mathbf{Y}$  then
24:         $\mathbf{Y} \leftarrow \mathbf{X}_{\text{rep}}$ 
25:      end if
26:    end if
27:    if  $\mathbf{Y} \prec_{\text{Deb}} \mathbf{X}_i$  then
28:       $\mathbf{X}_i \leftarrow \mathbf{Y}$ 
29:    end if
30:  end for
31: 按 Deb 规则更新当前最优解  $\mathbf{X}^*$ 
32: end for
33: return 由  $\mathbf{X}^*$  解码得到的路径  $\mathcal{P}^*$ 
```

其中各 $\mathbf{r}$ 为 $[0, 1]^{3K}$ 上的独立随机向量, $\odot$ 表示逐维乘积; a_e 、 a_b 、 a_d 、 a_s 和 a_u 为平衡精英、最优、差分、采样与随机扰动的固定调度系数, ω_d 为差分组合权重, η_t 和 μ_t 为随进程平滑变化的凸组合系数, 并满足 $\eta_t, \mu_t \geq 0$ 及 $\eta_t + \mu_t \leq 1$ 。上述设置在所有场景中保持一致。

3.2 CVF-AE 算法设计

CVF-AE 的新增环节形成连续闭环, 而非彼此独立的模块: 约束感知初始化回答如何进入潜在可行走廊, 状态调度决定何时介入, CVF 候选构造给出怎样移动, 保守接收判断修正是否值得保留。它们分别对应算法 2 中的初始化、状态识别、候选生成和候选接收。

3.2.1 约束感知初始化与参考弱引导

CVF-AE 在随机初始化之外引入低分辨率参考控制序列, 并重采样为与路径编码一致的内部控制点。该序列由平面分辨率 5m、垂向分辨率 4m 的三维栅格

A* 在占据、风险、边界和高度偏好代价上搜索得到。记参考控制点为 $\{\mathbf{q}_k^{\text{ref}}\}_{k=1}^K$ ，其向量化形式为

$$\mathbf{X}_{\text{ref}} = \text{vec}([\mathbf{q}_1^{\text{ref}\top}, \dots, \mathbf{q}_K^{\text{ref}\top}]^\top) \quad (21)$$

对引导个体，内部控制点在参考点附近扰动；扰动半径由局部净空和风险共同决定：

$$r_k = \max\left(r_{\min}, \frac{c_d d_{\text{clr}}(\mathbf{q}_k^{\text{ref}})}{1 + c_\phi r_{\text{obj}}(\mathbf{q}_k^{\text{ref}})}\right) \quad (22)$$

$$\mathbf{q}_{i,k}^{(0)} = \Pi_\Omega(\mathbf{q}_k^{\text{ref}} + \boldsymbol{\epsilon}_{i,k}) \quad \boldsymbol{\epsilon}_{i,k} \sim \mathcal{U}([-r_k, r_k]^3) \quad (23)$$

其中，上标 (0) 表示初始化（第 0 代），下标 i 和 k 分别表示种群个体与内部控制点索引。对第 i 个引导个体， $\{\mathbf{q}_{i,k}^{(0)}\}_{k=1}^K$ 按式 (1) 拼接为初始决策向量 $\mathbf{X}_i^{(0)} \in \mathbb{R}^{3K}$ 。 $d_{\text{clr}}(\cdot)$ 和 $r_{\text{obj}}(\cdot)$ 分别为局部最小裕度和风险密度， c_d 、 c_ϕ 、 $r_{\min}$ 分别控制净空缩放、风险收缩和最小扰动半径。生成点经投影和局部处理后进入种群；其余个体均匀初始化，复杂布局可加入固定走廊控制点模板。所有个体均按同一评价函数和 Deb 规则筛选，参考序列在迭代中仅提供弱方向 $\mathbf{d}_{\text{ref}}$ 。

该初始化仅提供进入潜在可行走廊的起点；后续介入由群体可行性、违反程度和搜索进展共同决定。

3.2.2 状态识别与保守调度

令 $\mathbf{X}_t^*$ 为第 t 代按 Deb 规则选取的最优个体， $J_t^* = J(\mathbf{X}_t^*)$ 。 ρ_f 、 $\bar{V}$ 和 ΔJ_{recent} 分别表示可行率、平均违反量和最近 w 个已完成迭代的目标改进：

$$\rho_f = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\mathbf{X}_i \text{ feasible}), \quad \bar{V} = \frac{1}{N} \sum_{i=1}^N V(\mathbf{X}_i) \quad (24)$$

$$\Delta J_{\text{recent}} = \frac{\max(0, J_{t-w}^* - J_t^*)}{\max(1, |J_{t-w}^*|)}, \quad w = 15 \quad (25)$$

当历史长度超过窗口 w 且 $\Delta J_{\text{recent}} < 10^{-4}$ 时认为搜索停滞。原始识别器还记录质量细化状态，所采用的保守调度仅激活形成、保持和恢复三种状态。设 χ_{stag} 为停滞事件的示性函数，则请求状态为

$$q_t = \begin{cases} \text{F}, & \neg \text{feasible}(\mathbf{X}^*) \\ \text{R}, & \chi_{\text{stag}} = 1 \wedge \rho_f < 0.55 \wedge \bar{V} \geq 6 \\ \text{P}, & \text{otherwise} \end{cases} \quad (26)$$

其中 q_t 为请求状态，F、P 和 R 分别表示形成、保持和恢复。 $\mathbf{X}^*$ 按 Deb 规则选取，因此 $\neg \text{feasible}(\mathbf{X}^*)$ 等价于当前种群尚无可行个体；形成条件优先于恢复条

表 1: CVF-AE 三状态的候选侧重与融合权重

s_t	内部基础方向侧重	$(\alpha_s, \beta_s, \gamma_s)$
F	参考/精英方向与均匀扰动	(.80, .40, .04)
P	最优/精英方向与局部差分	(.90, .38, .06)
R	差分恢复与高斯扰动	(.90, .28, .04)

件。非保持请求需连续确认 2 代，确认后的生效状态记为 s_t 。

CVF-AE 在每个生效状态下先构造内部基础候选。令 $\mathbf{d}_{\text{ref}} = \mathbf{X}_{\text{ref}} - \mathbf{X}_i$ ，并沿用前文的 $\mathbf{d}_{\text{best}}$ 、 $\mathbf{d}_{\text{elite}}$ 、 $\mathbf{d}_{\text{sample}}$ 、 $\mathbf{d}_{ab}$ 和 $\mathbf{d}_{cd}$ ，则

$$\begin{aligned} \mathbf{D}_{\text{AE}}^{(s_t)} = & c_b \mathbf{r}_b \odot \mathbf{d}_{\text{best}} + c_e \mathbf{r}_e \odot \mathbf{d}_{\text{elite}} \\ & + c_s \mathbf{r}_s \odot \mathbf{d}_{\text{sample}} + c_r \mathbf{r}_r \odot \mathbf{d}_{\text{ref}} \\ & + c_1 \mathbf{d}_{ab} + c_2 \mathbf{d}_{cd} \\ & + c_u \boldsymbol{\xi} \odot (\mathbf{u} - \mathbf{l}) \\ & + c_g \boldsymbol{\zeta} \odot (\mathbf{u} - \mathbf{l}) \end{aligned} \quad (27)$$

其中各 $\mathbf{r}$ 为独立均匀随机向量， $\boldsymbol{\xi}$ 、 $\boldsymbol{\zeta}$ 分别为 $[-1, 1]^{3K}$ 上的均匀扰动和标准高斯扰动； c_b 至 c_g 由状态确定，部分系数随进程 $\tau = t/T$ 平滑变化。其状态化内部基础候选为

$$\mathbf{X}_{\text{AE}}^{(s_t)} = \Pi_\Omega\left((1 - \nu_s)(\mathbf{X}_i + \mathbf{D}_{\text{AE}}^{(s_t)}) + \nu_s \mathbf{X}_{\text{elite}}\right) \quad (28)$$

其中 ν_s 随进程缓慢增加，并在形成状态额外增强精英锚定。三种状态的方向侧重及固定 CVF 候选融合权重见表 1。

3.2.3 CVF 构建与压力分量

CVF 不依赖目标或约束函数的解析梯度，也不要求连续可微的势函数假设；它在控制点空间中将局部约束信息编码为有界、分段的候选修正方向。给定低密度路径采样集 $\tilde{\mathcal{P}} = \{\tilde{\mathbf{p}}_m\}_{m=1}^{\tilde{M}}$ ，采样点压力先分配到最近内部控制点：

$$k^*(m) = \arg \min_{1 \leq k \leq K} \|\tilde{\mathbf{p}}_m - \mathbf{q}_k\|_2 \quad (29)$$

记非曲率压力集合为

$$\begin{aligned} \mathcal{C}_{\text{path}} = & \{\text{obs}, \text{nfz}, \text{risk}, \text{alt}, \text{bnd}\}, \\ \mathbf{F}(\tilde{\mathbf{p}}_m) = & \sum_{c \in \mathcal{C}_{\text{path}}} \eta_c(s_t) \mathbf{f}_c(\tilde{\mathbf{p}}_m) \end{aligned} \quad (30)$$

其中 $\mathbf{f}_c(\tilde{\mathbf{p}}_m)$ 为采样点处第 c 类压力方向， $\eta_c(s_t)$ 为生效状态相关权重；局部违反程度由分量幅值体现。对于




图 1: CVF 采样压力的映射、平均与曲率合成示意。上图展示五种代表性主导约束压力及其到控制点 $\mathbf{q}_k$ 的映射，下图展示压力平移、平均以及与曲率分量的合成。

含有多个空间元素的分量，先对同类元素的压力求和：

$$\begin{aligned} \mathbf{f}_{\text{obs}}(\mathbf{p}) &= \sum_{\mathcal{B}_j \in \mathcal{O}} \mathbf{f}_{\text{obs}}(\mathbf{p}; \mathcal{B}_j), \\ \mathbf{f}_{\text{nfz}}(\mathbf{p}) &= \sum_{\mathcal{Z}_j \in \mathcal{Z}} \mathbf{f}_{\text{nfz}}(\mathbf{p}; \mathcal{Z}_j), \\ \mathbf{f}_{\text{risk}}(\mathbf{p}) &= \sum_h \mathbf{f}_{\text{risk}}(\mathbf{p}; \mathcal{H}_h). \end{aligned} \quad (31)$$

形成状态加强障碍物、禁飞区和高度压力，保持状态采用较均衡的分量组合，恢复状态整体减弱约束牵引但保留障碍物和禁飞区方向。各状态使用固定权重，且不随测试场景调节；关键固定参数统一列于表 3。若多个采样点映射到同一控制点，则按命中次数平均压力。记

$$n_k = \sum_{m=1}^{\tilde{M}} \mathbb{I}(k^*(m) = k \wedge \|\mathbf{F}(\tilde{\mathbf{p}}_m)\|_2 > 0) \quad (32)$$

为映射到第 k 个控制点且压力非零的采样点数量，非曲率增量为

$$\Delta \mathbf{q}_k^{\text{path}} = \begin{cases} \frac{1}{n_k} \sum_{m: k^*(m)=k, \|\mathbf{F}(\tilde{\mathbf{p}}_m)\|_2 > 0} \mathbf{F}(\tilde{\mathbf{p}}_m), & n_k > 0 \\ 0, & n_k = 0 \end{cases} \quad (33)$$

图 1 示意采样压力到控制点 $\mathbf{q}_k$ 的映射、压力平移与平均，以及与曲率分量的合成过程。

障碍物分量 对于轴对齐障碍物 $\mathcal{B} = [x_1, x_2] \times [y_1, y_2] \times [z_1, z_2]$ ，令 $\mathbf{c}_{\mathcal{B}}(\mathbf{p})$ 为 $\mathbf{p}$ 在箱体上的最近点。若 $\mathbf{p}$ 位于障碍物外部，定义

$$\mathbf{d}_o = [p_x - c_x, p_y - c_y, \lambda_z(p_z - c_z)]^T, \quad d_o = \|\mathbf{d}_o\|_2 \quad (34)$$

当 $0 < d_o \leq r_o$ 时，障碍物压力为

$$\mathbf{f}_{\text{obs}}(\mathbf{p}; \mathcal{B}) = \frac{r_o - d_o}{r_o} \frac{\mathbf{d}_o}{d_o} \quad (35)$$

当 $d_o > r_o$ 时，该分量为 $\mathbf{0}$ 。若 $\mathbf{p}$ 位于障碍物内部，则选择最近的水平外侧面法向 $\mathbf{n}_{\min}$ ，并令

$$\mathbf{f}_{\text{obs}}(\mathbf{p}; \mathcal{B}) = (r_o + d_{\min}) \mathbf{n}_{\min} \quad (36)$$

其中 $d_{\min}$ 为到最近水平面的穿透深度， r_o 为障碍缓冲半径， λ_z 为固定垂向缩放系数。

禁飞区分量 设第 j 个柱状禁飞区为 $\mathcal{Z}_j = (\mathbf{c}_j, r_j, z_j^-, z_j^+)$ 。若 $p_z \notin [z_j^-, z_j^+]$ ，该分量为零；否则令 $\mathbf{d}_j = [p_x - c_{j,x}, p_y - c_{j,y}, 0]^T$ ， $d_j = \|\mathbf{d}_j\|_2$ ，并定义

$$\mathbf{f}_{\text{nfz}}(\mathbf{p}; \mathcal{Z}_j) = \begin{cases} (r_j - d_j + r_n) \frac{\mathbf{d}_j}{d_j}, & d_j \leq r_j \\ \frac{r_j + r_n - d_j}{r_n} \frac{\mathbf{d}_j}{d_j}, & r_j < d_j \leq r_j + r_n \\ 0, & d_j > r_j + r_n \end{cases} \quad (37)$$

其中 r_n 为禁飞区外侧缓冲半径；当 d_z 接近零时使用固定水平单位方向避免除零。

风险分量 对风险热点 $\mathcal{H}_h = (\mathbf{c}_h, \sigma_h, a_h)$ ，令 $\tilde{\mathbf{d}}_h = [p_x - c_{h,x}, p_y - c_{h,y}, \lambda_z(p_z - c_{h,z})]^T$ ，并定义

$$\phi_h^{\text{CVF}}(\mathbf{p}) = a_h \exp\left(-\frac{\|\tilde{\mathbf{d}}_h\|_2^2}{2\sigma_h^2}\right) \quad (38)$$

仅当 $\phi_h^{\text{CVF}}(\mathbf{p}) > \phi_0$ 时触发风险压力：

$$\mathbf{f}_{\text{risk}}(\mathbf{p}; \mathcal{H}_h) = \kappa_r (\phi_h^{\text{CVF}}(\mathbf{p}) - \phi_0) \frac{\tilde{\mathbf{d}}_h}{\|\tilde{\mathbf{d}}_h\|_2} \quad (39)$$

其中 ϕ_0 为风险激活阈值， κ_r 为压力强度系数；当 $\|\tilde{\mathbf{d}}_h\|_2$ 接近零时使用固定单位方向避免除零。

高度和边界分量 记 $z_l = z_{\min}$ ， $z_u = z_{\max}$ ，高度分量为

$$f_{\text{alt},z}(\mathbf{p}) = \begin{cases} z_l - p_z, & p_z < z_l \\ z_u - p_z, & p_z > z_u \\ \lambda_z(z_l + b_z - p_z), & z_l \leq p_z < z_l + b_z \\ -\lambda_z(p_z - z_u + b_z), & z_u - b_z < p_z \leq z_u \\ 0, & \text{otherwise} \end{cases} \quad (40)$$

将该标量与弱参考高度项组合为三维高度压力

$$\mathbf{f}_{\text{alt}}(\mathbf{p}) = [0, 0, f_{\text{alt},z}(\mathbf{p}) + \lambda_{\text{ref}}(z_{\text{ref}} - p_z)]^T, \quad (41)$$

其中 b_z 为高度缓冲宽度, λ_{ref} 为固定弱引导系数。水平边界分量为

$$f_{\text{bnd},x}(\mathbf{p}) = \begin{cases} x_{\min} + b_b - p_x, & p_x < x_{\min} + b_b \\ x_{\max} - b_b - p_x, & p_x > x_{\max} - b_b \\ 0, & \text{otherwise} \end{cases} \quad (42)$$

$f_{\text{bnd},y}(\mathbf{p})$ 按同样方式定义

相应的三维边界压力写为

$$\mathbf{f}_{\text{bnd}}(\mathbf{p}) = [f_{\text{bnd},x}(\mathbf{p}), f_{\text{bnd},y}(\mathbf{p}), 0]^T. \quad (43)$$

其中 b_b 为 CVF 的水平边界压力宽度; 硬边界仍由投影保证。

转弯分量 若连续控制点形成的局部转角 ϑ_k 接近或超过阈值, 则施加局部平滑方向。 ϑ_k 按式 (15) 计算, 但以控制点 $\mathbf{q}_k$ 替代采样点 $\mathbf{p}_m$:

$$\mathbf{F}_{k,\text{curv}} = \begin{cases} \gamma_{\text{curv}} \left[\frac{1}{2}(\mathbf{q}_{k-1} + \mathbf{q}_{k+1}) - \mathbf{q}_k \right], & \vartheta_k \geq \theta_c \\ \mathbf{0}, & \text{otherwise} \end{cases} \quad (44)$$

其中 γ_{curv} 为平滑强度, $\theta_c = \alpha_{\text{curv}}\theta_{\max}$, α_{curv} 为转弯压力的激活比例。最终控制点增量为非曲率平均压力与状态加权曲率压力之和:

$$\Delta \mathbf{q}_k = \Delta \mathbf{q}_k^{\text{path}} + \eta_{\text{curv}}(s_t) \mathbf{F}_{k,\text{curv}} \quad (45)$$

3.2.4 有界融合与稀疏接收

上述压力仅提供局部移动建议。为避免其叠加后过度改变主体搜索, CVF-AE 依次限制步长、融合质量方向, 并仅对少量候选执行保守接收。

将全部内部控制点增量向量化后得到未截断 CVF 步长:

$$\tilde{\mathbf{D}}_{\text{CVF}} = \text{vec}([\Delta \mathbf{q}_1^T, \dots, \Delta \mathbf{q}_K^T]^T) \quad (46)$$

对该向量依次施加逐维截断、强度缩放和整体范数截断:

$$\mathbf{D}_{\text{CVF}}^{(0)} = \kappa_{\text{cvf}} \left[\text{clip} \left(\tilde{\mathbf{D}}_{\text{CVF},j}, \rho_{\text{step}}(u_j - l_j) \right) \right]_{j=1}^{3K} \quad (47)$$

$$h_{\text{cvf}} = \rho_{\text{norm}} \|\mathbf{u} - \mathbf{l}\|_2,$$

$$\mathbf{D}_{\text{CVF}} = \begin{cases} \mathbf{D}_{\text{CVF}}^{(0)}, & \|\mathbf{D}_{\text{CVF}}^{(0)}\|_2 \leq h_{\text{cvf}} \\ \frac{h_{\text{cvf}} \mathbf{D}_{\text{CVF}}^{(0)}}{\|\mathbf{D}_{\text{CVF}}^{(0)}\|_2}, & \text{otherwise} \end{cases} \quad (48)$$

其中 κ_{cvf} 控制总体强度, ρ_{step} 和 ρ_{norm} 分别限制逐维和整体步长。

质量引导方向 $\mathbf{D}_Q$ 由当前最优解、采样精英个体和控制点平滑项共同构成。对内部控制点序列 $\{\mathbf{q}_k\}_{k=1}^K$, 当 $k = 2, \dots, K-1$ 时, 局部平滑增量为

$$\Delta \mathbf{q}_{\text{sm},k} = 0.10(\mathbf{q}_{k-1} - 2\mathbf{q}_k + \mathbf{q}_{k+1}), \quad (49)$$

两端增量为零, 将全部增量向量化为 $\mathbf{D}_{\text{sm}}$ 。取 $\omega_Q = 0.60$ 、 $\rho_Q = 0.05(\mathbf{u} - \mathbf{l})$, 则

$$\mathbf{G}_Q = \omega_Q(\mathbf{X}^* - \mathbf{X}_i) + (1 - \omega_Q)(\mathbf{X}_{\text{elite}} - \mathbf{X}_i), \quad (50)$$

$$\mathbf{D}_Q = \text{clip}(\mathbf{G}_Q + \mathbf{D}_{\text{sm}}, \rho_Q)$$

状态融合方向和 CVF 候选为

$$\begin{aligned} \mathbf{D}_s &= \alpha_s \mathbf{D}_{\text{AE}}^{(s_t)} + \beta_s \mathbf{D}_{\text{CVF}} + \gamma_s \mathbf{D}_Q \\ \mathbf{X}_{\text{CVF}} &= \Pi_{\Omega} \left((1 - \mu_t)(\mathbf{X}_i + \mathbf{D}_s) + \mu_t \mathbf{X}_{\text{elite}} \right) \end{aligned} \quad (51)$$

状态化内部基础候选 $\mathbf{X}_{\text{AE}}^{(s_t)}$ 始终生成, CVF 候选 $\mathbf{X}_{\text{CVF}}$ 仅对触发个体生成。

设第 t 代状态为 s_t , 对应触发比例为 r_{s_t} , 则

$$N_{\text{cvf}}^{(t)} \leq \max\{1, \text{round}(r_{s_t} N)\} \quad (52)$$

本文将满足 $\varepsilon_v < V(\mathbf{X}_i) \leq 15$ 的个体定义为近可行不可行个体。F/P 状态仅在当前标量适应度前 45% 的此类对象中触发, R 状态允许全部此类对象; 三种状态的名义比例分别为 $r_F = 0.06$ 、 $r_P = 0.06$ 和 $r_R = 0.04$ 。出现可行最优解后, CVF 每 3 代检查一次, 且单代比例不超过 0.03。

每个触发个体先评价基础候选; 若生成 CVF 候选, 则二者按局部规则比较:

$$\mathbf{X}_{\text{CVF}} \prec_{\text{Deb}} \mathbf{X}_{\text{AE}}^{(s_t)}, \quad J(\mathbf{X}_{\text{CVF}}) \leq J(\mathbf{X}_{\text{AE}}^{(s_t)}) \quad (53)$$

式 (53) 要求 CVF 候选同时在 Deb 顺序更优且综合适应度不增加, 否则保留状态化内部基础候选。随后, 当 $\tau \geq 0.15$ 时, 仅对标量适应度前 30% 且满足 $\varepsilon_v < V(\mathbf{Y}) \leq 25$ 的少量候选执行一次局部修复, 单代数量不超过 $\max\{1, \text{round}(0.08N)\}$; 修复结果仅在 Deb 规则下更优时保留。

3.3 算法复杂度

以下以完整路径评价为主导计算成本，并沿用前文的种群、迭代、路径采样和控制点记号；令 G 表示参与路径检查的空间元素总数。基础搜索的候选评价次数为 $O(TN)$ ，单次路径评价代价为

$$O(M(G + K)) \quad (54)$$

因此基础搜索的评价工作量为 $O(TNM(G + K))$ 。若每代 CVF 和局部修复触发数分别为 N_{cvf} 和 N_{rep} ，则二者的额外工作量为

$$O(T\{N_{\text{cvf}}[M + \widetilde{M}] + N_{\text{rep}}M\}(G + K)) \quad (55)$$

初始化时需完成 N 个初始个体的评价，至多对 N_{init} 个体执行一次修复，其一次性主导开销为

$$O((N + N_{\text{init}})M(G + K)) \quad (56)$$

参考路径预处理另包含 $O(QG)$ 的栅格占据与代价构造，以及 $O(Q^2)$ 的数组扫描式 A* 核心搜索。候选向量更新、状态统计和种群排序不涉及完整路径评价，未纳入上述主导成本。由于 $N_{\text{cvf}}, N_{\text{rep}} \ll N$ ，迭代阶段的额外开销主要由少量触发个体承担，CVF-AE 的主导渐近复杂度仍为

$$O(TNM(G + K)) \quad (57)$$

4 实验结果与分析

本章围绕 CVF-AE 在约束逐步收紧场景中的可行性与路径质量组织证据。主对比以可行率和平均排名为主，分布、收敛曲线和代表性路径分别补充稳定性、搜索过程与几何形态；消融实验定位各环节的作用。统计检验和评价开销分别量化主对比差异与稀疏介入代价。代表性路径的预设阈值辅助复核标记仅用于解释可视化形态，不构成安全认证或独立优化目标。

4.1 整体实验设置

每次独立运行均在同一台本地工作站上由单个 MATLAB 进程完成：Intel(R) Core(TM) i5-14600KF 3.50 GHz, 32 GB 内存, 64 位系统, MATLAB R2024b。效率主要由函数评价次数、CVF 触发规模 and 同配置评价比值刻画。

三维规划空间水平方向均为 $[0, 100] \times [0, 100]$ ，起点和终点分别为 $\mathbf{s} = [5, 5, 12]^T$ 和 $\mathbf{g} = [95, 95, 18]^T$ 。如表 2 所示，三个场景均含建筑物、柱状禁飞区和风险热点，约束密度、高度上界和风险分布逐步收紧；Scene 1/2 使用 $z_{\text{ref}} = 16$ ，Scene 3 使用 $z_{\text{ref}} = 14$ 。

表 3 同时列出公共实验配置与 CVF-AE 的关键固定参数。路径编码、评价函数、边界投影、种群规模、迭代次数和 Deb 可行性优先准则用于全部主对比算法和消融版本；参考、状态调度和 CVF 场参数仅定义 CVF-AE 及其消融版本。基线选择遵循覆盖性和可复现性原则：AE 作为基础进化搜索骨架，PSO [11]、GWO [12] 和 HHO [13] 代表经典群智能优化方法；ERIME 依据增强 RIME 文献中的精英反向学习与软/硬霜冰更新机制进行任务适配实现 [14]，MSCSO 依据面向三维 UAV 路径规划的混沌初始化、Lévy-Metropolis 探索、SA-PSO 开发和精英变异机制实现 [15]。不同算法因内部候选与局部搜索机制不同，函数评价次数不强制相同，并在开销分析中单独报告。基线不调用 CVF 场、约束状态调度、稀疏可行性保持或 CVF-AE 专属初始化。消融实验采用独立于主对比的随机运行批次，并保持相同场景、运行次数、种群规模和迭代次数。

评价指标包括最终最佳适应度、可行率、函数评价次数和平均排名。代表性轨迹中的高空绕行、边界贴靠、过度绕行和控制点贴边四类固定阈值取逻辑或，作为预设阈值辅助复核标记，仅用于可视化和结果复核，不构成安全认证或独立优化目标。由于随机种子不作严格配对，CVF-AE 与各基线采用双侧 Wilcoxon rank-sum / Mann-Whitney U 检验 [16]，场景内采用 Holm 校正 [17]，并报告面向最小化问题定义的 Cliff's delta [18]。

表 2: 三维低空路径规划测试场景设置

场景	障碍物数	禁飞区数	风险热点数	高度范围
Scene 1	6	3	3	[8, 40]
Scene 2	10	2	3	[8, 32]
Scene 3	17	3	5	[8, 26]

4.2 主对比结果

图 2 首先从可行性和跨场景排名概括主对比结果。随着约束由 Scene 1 向 Scene 3 收紧，AE、PSO、GWO、HHO 和 MSCSO 的可行率出现不同程度下降，而 CVF-AE 与 ERIME 在本文离散采样判定下均保持 1.00。在此基础上，CVF-AE 的场景排名依次为 1、2

表 3: 实验设置与 CVF-AE 关键固定参数

类别	设置
路径编码	$K = 6$, 维度 18; 三次 B 样条, $M = 220$
搜索配置	$N = 30$, $T = 300$, 30 次独立运行
目标函数权重	$w_L = 1.00$, $w_E = 0.60$, $w_R = 1.20$, $w_S = 0.15$
能耗系数	$a_1 = 1.0$, $a_2 = 0.4$, $a_3 = 0.8$
参考与边界引导	$z_{\text{ref}} = (16, 16, 14)$ (Scene 1–3), $b_b = 6 \text{ m}$
违反惩罚与运动约束	$\lambda_{\text{obs}} = 150$, $\lambda_{\text{nfz}} = 200$, $\lambda_{\text{curv}} = 20$, $\lambda_{\text{alt}} = 30$; $\theta_{\text{max}} = 55^\circ$
状态调度	$w = 15$, 停滞阈值 10^{-4} , 恢复阈值 $\rho_f = 0.55$, $\bar{V} = 6$, 确认 2 代
CVF 场与截断	$\bar{M} = 64$; $\kappa_{\text{cvf}} = 0.65$, $\rho_{\text{step}} = 0.040$, $\rho_{\text{norm}} = 0.085$
几何、风险与转弯压力	$r_o = 7 \text{ m}$, $r_n = 7 \text{ m}$, $b_z = 3 \text{ m}$; $\phi_0 = 0.24$, $\kappa_r = 1.80$, $\gamma_{\text{curv}} = 0.22$, $\alpha_{\text{curv}} = 0.85$




图 2: 主对比算法的三场景可行率与基于最终适应度的平均场景排名

和 1, 以 1.33 的平均排名取得所选算法中的整体最优; MSCSO 和 ERIME 的平均排名分别为 2.00 和 2.67。

最终适应度的场景差异由图 3 给出。在 Scene 1 中, CVF-AE 的平均适应度为 298.5286, 均值最低且箱体较窄; Scene 2 中 MSCSO 以 295.0138 低于 CVF-AE 的 301.1934, 说明基础搜索对特定场景结构的适配仍会影响最终标量目标; 进入约束最密集的 Scene 3 后, CVF-AE 以 350.7658 略优于 ERIME 的 356.4928, 并保持 1.00 可行率。可行率与平均排名图回答约束收紧后的总体稳健性, 箱线图则补充各场景适应度的均值、中心位置、离散程度和运行间波动; 分布差异以后文 Holm 校正和 Cliff's delta 的结果为准。

在此基础上, 图 4 显示相同种群规模和迭代次数配置下的平均搜索过程。CVF-AE 在 Scene 1 和 Scene 3 中进入较低且稳定的适应度区间, Scene 2 中 MSCSO




图 3: 主对比算法的最终适应度分布 (菱形为均值)

的最终均值更低, 因而与分布图给出的场景差异相互对应。该图描述的是统一迭代配置下候选质量的演化, 不将不同算法的曲线解释为函数评价效率或严格收敛速度优势, 因为其单代候选评价次数并不强制相同。

数值与过程结果之后, 图 5 补充两个强约束场景中按统一规则选取的代表性运行。所选 Scene 2 运行中, CVF-AE 路径避开建筑足迹并沿可行走廊推进; 所选 Scene 3 运行则显示部分基线路径存在边界贴靠或较大绕行。该示例表明相近的标量目标可能对应不同几何形态, 可作为理解统计结果的形态证据, 但不替代重复运行数据。代表性路径及预设阈值辅助复核标记只服务于可视化和结果复核, 不参与优化、统计检验或排名。




图 5: 强约束场景中主对比算法的代表性路径 (按统一规则选取, 仅用于形态复核)

4.3 消融分析

主对比建立了完整闭环的结果, 消融实验进一步追问该结果由哪些环节支撑。V4 考察进入潜在可行走廊的先验, V2 考察按群体状态决定介入时机, V1 考




图 4: 三类测试场景的平均收敛曲线, 内嵌窗口放大相同相对位置的后期迭代区间




图 6: CVF-AE 关键模块消融: 三场景可行率与逐场景排名

察 CVF 增强候选分支, V3 考察候选生成后的稀疏可行性保持。为压缩表格, 消融版本记为 V0-V5: V0 为完整 CVF-AE; V1 去除 CVF 增强候选分支, 即不再生成第二候选, 因而同时移除了 CVF 压力、质量方向、状态化 AE 缩放和局部门控附加评价; V2 将三状态调度替换为固定保持状态; V3 去除迭代阶段的稀疏可行性保持, 但保留初始化阶段的一次修复; V4 去除约束感知初始化及其走廊模板, 但保留迭代阶段的参考弱方向和其余机制; V5 为 Base-AE。V5 给出移除整个候选增强闭环后的参照; 局部 Deb 优先且含惩罚综合适应度不增的接收规则作为保守边界保留, 其独立作用留待进一步实验验证。

图 6 先考察完整闭环移除后的变化: V0 在三个场景均排名第 1, 平均排名为 1.00, 并保持 1.00 可行率。移除整个候选增强闭环的 V5 在 Scene 1-3 的可行率分别降至 0.63、0 和 0; 相比之下, V1-V3 仍能形成可行解, 但场景排名均出现不同程度后移。结果提示, 强约束场景中的差异首先体现在可行候选的形成, 随后才体现为已可行解之间的适应度变化。

表 4 补充图 6 未承载的适应度、评价次数和触发

表 4: 消融版本的补充数值结果

Var.	$\bar{J}_1$	$\bar{J}_2$	$\bar{J}_3$	$\bar{n}_{eval}$	$n_{trig,3}$
V0	297.8318	300.6612	348.5856	9495.0	86.8
V1	298.2117	301.4330	350.3779	9454.1	0.0
V2	298.3037	301.8164	361.3123	9482.9	72.5
V3	300.7766	301.7253	374.0534	9074.3	89.9
V4	309.9484	314.4258	819.2527	9666.2	403.8
V5	654.0475	1597.4829	1643.7320	9030.0	0.0

注: $\bar{J}_k$ 为 Scene k 的平均最终适应度; $\bar{n}_{eval}$ 为三个场景的平均函数评价次数; $n_{trig,3}$ 为 Scene 3 的平均 CVF 触发数。

规模。尤其在 Scene 3 中, V4 去除约束感知初始化后可行率降至 0.47, 平均 CVF 触发数由 V0 的 86.8 上升至 403.8。结果提示, 在该困难走廊中仅依赖迭代阶段的局部修正不足以稳定进入可行区域; 初始化先验用于缩小早期搜索范围, 后续 CVF 则针对局部约束压力构造移动方向。

移除 CVF 增强候选分支后算法仍可保持可行, 但三场景适应度分别从 297.8318、300.6612 和 348.5856 升至 298.2117、301.4330 和 350.3779。图 7 进一步将 Scene 3 的数值变化对应到三维路径形态; 所选 V1 代表运行中仍可见较大的绕行或贴近约束边界的片段。该消融说明完整的 CVF 增强候选分支有助于可行区域内的搜索质量, 但不单独识别其中 CVF 压力方向、质量方向或第二候选结构各自的因果贡献。

CVF 所给的移动方向还需要由状态调度决定何时介入。将三状态调度替换为固定保持状态后, Scene 1/2 的变化较小, 而 Scene 3 的适应度升至 361.3123, 提示介入时机在约束更紧的场景中作用更明显。去除迭代阶段的稀疏可行性保持后, 三场景适应度分别升至 300.7766、301.7253 和 374.0534; 其三场景平均评价次数为 9074.3, 低于 V0 的 9495.0, 因而适应度退化并非




图 7: 关键模块消融版本在 Scene 3 中的代表性三维路径 (按统一规则选取, 仅用于形态复核)




图 8: CVP-AE 与所选基线的逐场景 Cliff's delta 及 Holm 校正关系

由完整方法的评价次数差异单独造成。该结果提示, 稀疏保持除增加少量修复评价外, 还用于维护已形成的可行趋势。

4.4 统计显著性与评价开销

图 8 将图 3 中的观察转化为逐场景分布比较。Holm 校正范围为每个场景内六次比较, CVP-AE 在 18 次比较中得到 13 胜、4 平和 1 负; 唯一显著劣势出现在 Scene 2, 对应 MSCSO 的标量适应度优势。单元格数值为面向最小化问题定义的 Cliff's delta, 正值表示 CVP-AE 分布更优; 符号 +、= 和 - 分别表示 Holm 校正后的胜、平和负关系。结合可行率、平均排名和重复运行分布, 这些结果支持 CVP-AE 在多个场景中形成稳定的综合结果, 同时保留 Scene 2 中基础搜索适配带来的例外。

最后, 表 5 检验这种闭环是否依赖高频附加评价。主对比批次中, CVP-AE 在 Scene 1-3 的平均评价次数分别为 9569.5、9552.7 和 9362.5, CVP 触发率均低于 1%; 在独立消融批次中, 相对同配置 w/o-CVP 版本的评价次数比值为 1.002、1.001 和 1.010, 三场景平均额外评价约为 0.44%。这些数据说明当前实现未对

全种群施加高频约束修正, 额外评价主要来自少量候选的定向增强。

表 5: CVP-AE 评价开销与稀疏触发统计

Group	Sc.	nEvals	Trig.	Succ.	Rate	Ratio
Main	1	9569.5	25.0	22.4	0.28%	—
Main	2	9552.7	12.4	9.5	0.14%	—
Main	3	9362.5	83.8	56.4	0.93%	—
Abl.	1	9566.4	21.1	19.2	0.22%	1.002
Abl.	2	9551.6	10.6	7.9	0.11%	1.001
Abl.	3	9367.1	86.8	59.5	0.93%	1.010

注: Main 为主对比批次中的 CVP-AE, Abl. 为独立消融批次中的完整 CVP-AE; Trig. 和 Succ. 分别为平均触发和被接收的 CVP 候选数, Rate = Trig./(NT), Ratio 为相对同配置 w/o-CVP 版本的评价次数比。

综合来看, CVP-AE 在所选代表性基线中保持 1.00 可行率并取得最佳平均排名, 同时通过稀疏触发控制额外评价开销, 可作为强约束低空路径规划中兼顾可行性、可视化轨迹复核和评价开销的候选生成框架。

5 结论

本文面向障碍物、柱状禁飞区、高度边界和风险热点共同作用的强约束三维低空路径规划问题, 提出 CVP-AE。其核心不在于以额外惩罚项替代原有目标, 而是将局部约束信息前移至候选生成阶段, 并保持评价函数和 Deb 可行性优先准则不变。具体而言, 约束感知初始化先将部分种群置于潜在可行走廊附近; 状态调度再依据种群可行性、违反程度和搜索进展决定介入时机; CVP 将障碍物、禁飞区、风险、高度、边界和转弯信息映射为控制点修正方向, 并通过逐维与整体步长截断限制其影响范围; 最后, CVP 候选须同时满足局部 Deb 更优和综合适应度不增才可替代内部基础候选。由此, 算法形成了“引导进入-按需介入-受限修正-保守保留”的闭环, 使约束信息能够改善候选质量, 而不演变为对全种群的强制修复。

三类约束逐步收紧的低空场景支持该闭环设计。在本文固定离散采样判定下, CVP-AE 在所选代表性基线中三场景可行率均为 1.00, 以 1.33 的平均排名取得整体最优, 并在约束最密集的 Scene 3 中保持较优的最终适应度。消融结果进一步说明各环节的必要性: 移除完整候选增强闭环后, 三个场景的可行率降至 0.63、0 和 0; 去除约束感知初始化时, Scene 3 的可行率降至 0.47 且 CVP 触发数显著增加; 去除状态调度或稀疏可行性保持也会损害强约束场景中的路径质量。完整方

法相对于同配置 w/o-CVF 版本的三场景平均额外评价次数约为 0.44%，表明方法收益来自有针对性的稀疏介入，而非全种群额外修复。

本文结论限于静态合成场景及固定采样下的数值可行性。后续可在真实地图与动态障碍环境中结合连续碰撞验证、在线重规划和飞行动力学/轨迹跟踪控制，进一步检验 CVF-AE 的工程适用性。

致谢

基金、致谢和作者声明内容待补。

利益冲突

利益冲突声明待补。

数据可用性声明

数据可用性声明待补。

参考文献

- [1] Pawan Kumar, Kunwar Pal, and Mahesh Chandra Govil. Comprehensive review of path planning techniques for unmanned aerial vehicles (uavs). *ACM Computing Surveys*, 58(3):1–44, 2025. doi: 10.1145/3737280.
- [2] Soheila Ghambari, Mahmoud Golabi, Laetitia Jourdan, Julien Lepagnot, and Lhassane Idoumghar. Uav path planning techniques: a survey. *RAIRO - Operations Research*, 58(4):2951–2989, 2024. doi: 10.1051/ro/2024073.
- [3] Daison Darlan, Oladayo S. Ajani, and Rammohan Mallipeddi. Evolutionary algorithm with domain-specific operators for uav path planning. *Swarm and Evolutionary Computation*, 101:102267, 2026. doi: 10.1016/j.swevo.2025.102267.
- [4] Ben Niu, Yongjin Wang, Jing Liu, and Gabriel Xiao-Guang Yue. Path planning for unmanned aerial vehicles in complex environment based on an improved continuous ant colony optimisation. *Computers and Electrical Engineering*, 123: 110034, 2025. doi: 10.1016/j.compeleceng.2024.110034.
- [5] Zengxin Chen, Zhihao Luo, Xiaojie Jin, and Jianmai Shi. Multi-uav path planning problem with biased sampling, candidate evaluation, and path reconfiguration in complex environment with threats. *Expert Systems with Applications*, 291: 128558, 2025. doi: 10.1016/j.eswa.2025.128558.
- [6] Xia Wang, Yaning Feng, Jianing Tang, Zhongbin Dai, and Wei Zhao. A uav path planning method based on the framework of multi-objective jellyfish search algorithm. *Scientific Reports*, 14(1):28058, 2024. doi: 10.1038/s41598-024-79323-0.
- [7] Kai Meng, Binghong Wu, Bin Xin, Fang Deng, and Chen Chen. Multiobjective multi-uav path planning via evolutionary multitasking optimization with adaptive operator selection and knowledge fusion. *Swarm and Evolutionary Computation*, 99:102145, 2025. doi: 10.1016/j.swevo.2025.102145.
- [8] Oussama Khatib. Real-time obstacle avoidance for manipulators and mobile robots. *The International Journal of Robotics Research*, 5(1):90–98, 1986. doi: 10.1177/027836498600500106.
- [9] Huidong Liu, Xianlei Long, Yong Li, Jinjin Yan, Mingyan Li, Chao Chen, Fuqiang Gu, Huayan Pu, and Jun Luo. Adaptive multi-uav cooperative path planning based on novel rotation artificial potential fields. *Knowledge-Based Systems*, 317: 113429, 2025. doi: 10.1016/j.knosys.2025.113429.
- [10] Kalyanmoy Deb. An efficient constraint handling method for genetic algorithms. *Computer Methods in Applied Mechanics and Engineering*, 186 (2-4):311–338, 2000. doi: 10.1016/S0045-7825(99)00389-8.
- [11] James Kennedy and Russell Eberhart. Particle swarm optimization. In *Proceedings of ICNN'95*

- *International Conference on Neural Networks*, volume 4, pages 1942–1948, 1995. doi: 10.1109/ICNN.1995.488968.
- [12] Seyedali Mirjalili, Seyed Mohammad Mirjalili, and Andrew Lewis. Grey wolf optimizer. *Advances in Engineering Software*, 69:46–61, 2014. doi: 10.1016/j.advengsoft.2013.12.007.
- [13] Ali Asghar Heidari, Seyedali Mirjalili, Hossam Faris, Ibrahim Aljarah, Majdi Mafarja, and Huiling Chen. Harris hawks optimization: Algorithm and applications. *Future Generation Computer Systems*, 97:849–872, 2019. doi: 10.1016/j.future.2019.02.028.
- [14] Cankun Xie, Shaobo Li, Xinqi Qin, Shengwei Fu, and Xingxing Zhang. Multiple elite strategy enhanced RIME algorithm for 3d UAV path planning. *Scientific Reports*, 14:21734, 2024. doi: 10.1038/s41598-024-72279-1.
- [15] Zhengsheng Zhan, Dangyue Lai, Canjian Huang, Zhixiang Zhang, Yongle Deng, and Jian Yang. MSCSO: A modified sand cat swarm algorithm for 3d UAV path planning in complex environments with multiple threats. *Sensors*, 25(9):2730, 2025. doi: 10.3390/s25092730.
- [16] H. B. Mann and D. R. Whitney. On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1):50–60, 1947. doi: 10.1214/aoms/1177730491.
- [17] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979. URL <https://www.jstor.org/stable/4615733>.
- [18] Norman Cliff. Dominance statistics: Ordinal analyses to answer ordinal questions. *Psychological Bulletin*, 114(3):494–509, 1993. doi: 10.1037/0033-2909.114.3.494.